Minería de datos aplicada al análisis y predicción de la gravedad de los siniestros viales en Bogotá D.C.

Segunda entrega — Ciclo KDD: dominio, selección, limpieza, preprocesamiento y transformación de datos

Juan Esteban Castillo Baquero — ID 852500

Minería de Datos — Corporación Universitaria Minuto de Dios (UNIMINUTO) — 16/10/2026

Índice

1 Introducción y justificación **3**
1.1 Contexto del fenómeno . . . 3
1.2 Justificación: por qué minería de datos . . . 3
1.3 Objetivos . . . 3

2 Fase 1 de KDD — Dominio del problema **4**
2.1 Preguntas de investigación e hipótesis . . . 4
2.2 Variables críticas esperadas y beneficio tangible . . . 4
2.3 Restricción conceptual: qué se puede usar como predictor . . . 5

3 Fase 2 de KDD — Selección de datos **5**
3.1 Fuente de origen . . . 5
3.2 Diccionario de variables y decisión de selección . . . 5
3.3 Justificación de variables descartadas y excluidas . . . 5
3.4 Un hallazgo de fuga de objetivo en los propios datos . . . 7

4 Fase 3 de KDD — Limpieza y preprocesamiento **7**
4.1 Principio rector: cero fuga de datos . . . 7
4.2 Auditoría de integridad y duplicados . . . 7
4.3 Inconsistencias, categorías ambiguas y errores de captura . . . 7
4.4 Partición estratificada Train/Test . . . 9
4.5 Valores faltantes: diagnóstico y estrategia . . . 10
4.6 Valores atípicos (outliers) . . . 11

5 Fase 4 de KDD — Transformación e ingeniería de características **13**
5.1 Variables derivadas . . . 13
5.2 Codificación de variables categóricas . . . 14
5.3 Normalización de atributos numéricos . . . 14
5.4 Reducción de dimensionalidad: PCA . . . 15
5.5 Verificación anti-fuga de datos . . . 17

6 Exploración sobre el conjunto Train **17**
6.1 Desbalance de la variable objetivo 18
6.2 Franja horaria, tipo de día y localidad 18
6.3 Actores viales vulnerables 20

7 Conclusiones de la entrega y trabajo siguiente **20**
7.1 Lecciones aprendidas 20
7.2 Limitaciones técnicas 21
7.3 Trabajo futuro (siguientes entregas) 21

Anexos **21**
Anexo A. Estructura del proyecto entregado 21
Anexo B. Columnas del conjunto de modelamiento 22
Anexo C. Entorno de ejecución 22

1 Introducción y justificación

1.1 Contexto del fenómeno

Cada siniestro vial ocurrido en Bogotá D.C. es registrado por la autoridad de tránsito en el lugar de los hechos mediante el Informe Policial de Accidentes de Tránsito (IPAT) y consolidado por la Secretaría Distrital de Movilidad en el Sistema de Información Geográfico de Accidentes de Tránsito (SIGAT). El registro captura la fecha y hora del evento, su ubicación, la clase de siniestro, los vehículos involucrados y las características de los actores viales afectados.

Mediante el Decreto 494 de 2023 la ciudad adoptó el Plan Distrital de Seguridad Vial 2023–2032, cuya meta es reducir en 50 % el número de víctimas fatales tomando como línea base el año 2022. Las medidas disponibles para alcanzar esa meta (control de velocidad, rediseño de intersecciones, señalización, campañas dirigidas a actores viales específicos y distribución del patrullaje) son costosas y limitadas, mientras que los siniestros **no se distribuyen de manera homogénea**: se concentran en ciertos corredores, franjas horarias y tipos de usuario de la vía.

El conjunto de datos público utilizado en este proyecto reúne 196.152 siniestros registrados entre 01/01/2015 y 31/12/2020, con 422.416 registros de actores viales y 371.605 registros de vehículos. De ellos, solo 1,5 % terminó en víctimas fatales: el evento de mayor interés para la política pública es, a la vez, el más raro.

1.2 Justificación: por qué minería de datos

Hoy el análisis institucional es mayoritariamente **descriptivo y agregado** (conteos por localidad, año o clase de siniestro). Ese enfoque responde dónde y cuántos, pero no permite (i) anticipar el nivel de gravedad esperado de un evento dadas sus condiciones, ni (ii) identificar **combinaciones** de condiciones (tipo de actor, clase de vehículo, momento del día, localidad) cuyo efecto conjunto es distinto de la suma de sus partes. La minería de datos aporta modelos de clasificación que cuantifican esa relación y técnicas de agrupamiento que segmentan la siniestralidad en perfiles de riesgo con recomendaciones diferenciadas. El valor estratégico para la toma de decisiones es la **focalización**: orientar obras de infraestructura, operativos de control y campañas hacia donde el impacto sobre la reducción de víctimas fatales sea mayor.

1.3 Objetivos

Objetivo general. Construir y evaluar un modelo de minería de datos que permita clasificar la gravedad de un siniestro vial en Bogotá (solo daños materiales, con heridos, con víctimas fatales) a partir de las condiciones del evento, e identificar perfiles de riesgo que apoyen la focalización de intervenciones de seguridad vial.

Cuadro 1: Objetivos específicos mapeados a las fases del proceso. Esta entrega cubre hasta el preprocesamiento y la transformación de datos (fases 3 y 4 de KDD en los lineamientos del curso).

Objetivo específico	Fase del proceso	Alcance
1. Integrar Siniestros, Vehículos y Actor Vial en una tabla analítica a nivel de siniestro con el diccionario oficial.	KDD 2–3 (selección, limpieza)	Esta entrega
2. Caracterizar la siniestralidad por localidad, franja horaria, día y tipo de actor, cuantificando el desbalance de la variable objetivo.	KDD 1–2 (dominio, exploración sobre Train)	Esta entrega
3. Construir variables derivadas de la dimensión temporal y del perfil de los involucrados.	KDD 4 (transformación)	Esta entrega
4. Entrenar y comparar al menos tres técnicas de clasificación con métricas para clases desbalanceadas.	KDD 5 (minería de datos)	Entrega siguiente
5. Aplicar agrupamiento para identificar perfiles de alto riesgo e interpretarlos como recomendaciones de política.	KDD 5 e interpretación; CRISP-DM 6	Entrega siguiente

2 Fase 1 de KDD — Dominio del problema

2.1 Preguntas de investigación e hipótesis

La entidad necesita entender qué combinación de condiciones está asociada con los desenlaces más graves. Se formulan las siguientes preguntas, cada una con su hipótesis de trabajo:

Pregunta analítica	Hipótesis
P1. ¿Participar un actor vial vulnerable modifica la gravedad del siniestro?	**H1.** La participación de actores viales vulnerables (peatones y motociclistas) se asocia significativamente con mayor gravedad, por encima del efecto de la clase de siniestro o la localidad.
P2. ¿Importan el momento del día y el tipo de día?	**H2.** Los siniestros en franjas nocturnas y fines de semana tienen mayor probabilidad de desenlace fatal que los diurnos de días hábiles.
P3. ¿Existen perfiles de siniestro diferenciables?	**H3.** Existen agrupaciones según la combinación de localidad, franja horaria y tipo de actor, que segmentan la siniestralidad en perfiles de riesgo con intervenciones distintas.

2.2 Variables críticas esperadas y beneficio tangible

- **Variable objetivo:** gravedad del siniestro, con tres clases ordenadas: Solo daños, Con heridos y Con muertos.
- **Predictores esperados:** tipo de actor vial (peatón, ciclista, motociclista), clase de vehículo y su heterogeneidad, franja horaria, día de la semana y tipo de día (hábil, fin de semana, festivo), localidad, clase de siniestro y diseño del lugar.

- **Usuarios y beneficio:** la Secretaría Distrital de Movilidad y la autoridad de tránsito pueden priorizar intervenciones de infraestructura, programar operativos de control y diseñar campañas dirigidas a grupos específicos, con una herramienta que estime el nivel de gravedad esperado y señale perfiles de riesgo combinados.

2.3 Restricción conceptual: qué se puede usar como predictor

Un modelo útil para la toma de decisiones solo puede emplear información disponible **sobre las condiciones del evento**, no sobre sus consecuencias. Por eso el estado de los actores (ileso, herido, muerto), que define la gravedad, jamás entra como predictor; se usa únicamente para auditar la consistencia de la variable objetivo (Sección 4.3). Este criterio se desarrolla con un caso concreto en la Sección 3.4.

3 Fase 2 de KDD — Selección de datos

3.1 Fuente de origen

Los datos provienen del conjunto abierto **"Siniestros Viales Consolidados Bogotá D.C."** de la Secretaría Distrital de Movilidad, publicado en el portal de Datos Abiertos de Bogotá (`datosabiertos.bogota.gov.co`). Es un libro de Excel (≈ 49 MB) con cinco hojas, que se descarga y exporta a CSV con `scripts/00_descarga_datos.R` hacia `datos/raw/`. El diccionario de datos oficial viene en la propia hoja `DICCIONARIO`.

Cuadro 3: Estructura del consolidado oficial de siniestros viales.

Hoja	Filas	Granularidad	Uso en el proyecto
SINIESTROS	196.152	Un registro por siniestro (llave CODIGO_ACCIDENTE)	Núcleo analítico y variable objetivo
ACTOR_VIAL	422.416	Un registro por persona involucrada	Perfil de involucrados
VEHICULOS	371.605	Un registro por vehículo involucrado	Perfil de vehículos
HIPOTESIS	233.819	Una o más causas probables por siniestro	Descartada (ver 3.3)
DICCIONARIO	211	Códigos y descripciones	Decodificación de categorías

La integración requiere pasar de tres granularidades (siniestro, persona, vehículo) a una sola **tabla analítica a nivel de siniestro**. El resultado final es una fila por siniestro con 50 columnas.

3.2 Diccionario de variables y decisión de selección

3.3 Justificación de variables descartadas y excluidas

1. **`HIPOTESIS` (causa probable).** Se asigna después de la investigación del siniestro; no está disponible al momento de pronosticar la gravedad y su uso introduciría información posterior al hecho. Se descarta.

Cuadro 4: Diccionario de variables disponibles y decisión de selección.

Hoja	Variable	Tipo	Descripción	Decisión
SINIESTROS	CODIGO_ACCIDENTE	Identificador	Llave del siniestro	Llave
SINIESTROS	FECHA	Fecha	Fecha del evento (dd/mm/aaaa)	Se usa: base de variables temporales
SINIESTROS	HORA	Hora	Hora del evento (hh:mm:ss)	Se usa: franja y hora cíclica
SINIESTROS	GRAVEDAD	Categórica (1/2/3)	1 Con muertos, 2 Con heridos, 3 Solo daños	Objetivo (auditada)
SINIESTROS	CLASE	Categórica	Choque, atropello, volcamiento, caída, incendio, otro, autolesión	Se usa
SINIESTROS	CHOQUE	Categórica	Con qué se chocó (vehículo, tren, semoviente, objeto fijo)	Se usa (NA estructural recodificado)
SINIESTROS	OBJETO_FIJO	Categórica	Tipo de objeto fijo impactado	Descartada (ver 3.3)
SINIESTROS	DIRECCION	Texto	Dirección nomenclada del evento	Solo se deriva via_avenida
SINIESTROS	CODIGO_LOCALIDAD	Categórica (1–20)	Localidad de Bogotá	Se usa
SINIESTROS	DISENO_LUGAR	Categórica	Tramo de vía, intersección, glorieta, puente...	Se usa
ACTOR_VIAL	CONDICION	Categórica	Conductor, motociclista, ciclista, peatón, pasajero	Se usa (excepto pasajero)
ACTOR_VIAL	ESTADO	Categórica	Ileso, herido, muerto	Excluida como predictor (define el objetivo)
ACTOR_VIAL	EDAD	Numérica (años)	Edad del actor	Se usa agregada (media, mín., máx.)
ACTOR_VIAL	SEXO	Categórica	Masculino, femenino, sin información	Se usa agregada (prop. mujeres)
VEHICULOS	CLASE	Categórica	Automóvil, moto, bus, camión, bicicleta...	Se usa agrupada
VEHICULOS	SERVICIO	Categórica	Oficial, público, particular, diplomático	Se usa (transporte público)
VEHICULOS	MODALIDAD	Categórica	Modalidad del servicio de transporte	Descartada (ver 3.3)
VEHICULOS	ENFUGA	Binaria S/N	El vehículo huyó del lugar	Se usa
HIPOTESIS	CODIGO_CAUSA	Categórica	Causa probable asignada al siniestro	Descartada (ver 3.3)

2. **`OBJETO_FIJO`.** Presenta 96,6 % de vacíos que son **estructurales** (solo se diligencia cuando `CHOQUE = Objeto fijo`), está subsumida por `tipo_choque` y generaría decenas de columnas casi vacías. Se descarta por exceso de valores vacíos y redundancia.
3. **`MODALIDAD` del vehículo.** Tiene 61,3 % de vacíos, también estructurales: solo se diligencia en transporte público (337 vacíos entre los vehículos de servicio público frente a 202.404 entre los particulares). La información útil ya está en `SERVICIO`. Se descarta.
4. **`DIRECCION`.** Texto libre de cardinalidad altísima. Solo se conserva un indicador derivado, `via_avenida` (la dirección inicia con AV, AK, AC o AU). La georreferenciación fina se deja como trabajo futuro.
5. **`ESTADO` del actor.** Define la gravedad; se usa exclusivamente para verificar la consistencia de la variable objetivo.
6. **Pasajeros/acompañantes.** Se excluyen de todas las variables derivadas (Sección 3.4).

3.4 Un hallazgo de fuga de objetivo en los propios datos

Al auditar la hoja `ACTOR_VIAL` se observó que los registros no son una lista completa de ocupantes: de 27.365 pasajeros registrados, solo 2 están ilesos; de 23.447 peatones, solo 2 lo están. En cambio, 300.220 de 306.534 conductores están ilesos. Es decir, **los pasajeros solo aparecen en la base cuando resultaron lesionados**. Contar pasajeros (o el total de personas registradas) equivaldría a leer la respuesta: un siniestro "con pasajeros registrados" es casi por construcción un siniestro con heridos o muertos.

Decisión: todas las variables derivadas del perfil de involucrados se calculan sobre conductores, motociclistas, ciclistas y peatones, y **no se emplean los pasajeros**. El peatón se conserva porque la hipótesis H1 lo exige y porque físicamente un atropello casi siempre lesiona; sin embargo se documenta que su alta asociación con la gravedad refleja en parte esa relación mecánica y no solo un "efecto de riesgo" independiente, un matiz que deberá considerarse al interpretar los modelos.

4 Fase 3 de KDD — Limpieza y preprocesamiento

4.1 Principio rector: cero fuga de datos

Se aplica la regla contra la fuga de datos con una separación estricta en dos tipos de operaciones:

- **Reglas deterministas de dominio** (fila a fila, sin aprender nada de los datos): decodificar categorías con el diccionario, corregir tipos, eliminar duplicados, anular edades imposibles, reconciliar la variable objetivo. Se ejecutan **antes** de la partición (`scripts/01_integracion_limpieza.R`) porque no estiman parámetros.
- **Estadísticas aprendidas** (medianas de imputación, topes de winsorización, medias y desviaciones, niveles de categorías, rotación del PCA): se calculan **solo con Train** en `ajustar_transformacion()` y se aplican de forma idempotente con `aplicar_transformacion()` a Train, Test y al futuro artefacto de despliegue (`scripts/02_particion_transformacion.R`). Los parámetros se guardan en `modelos/parametros_transformacion.rds`.

4.2 Auditoría de integridad y duplicados

Los 148 siniestros sin actores ni vehículos (24 con heridos y 124 solo daños; **ninguno fatal**) no aportan atributos con los cuales construir las variables derivadas. Su eliminación no altera la clase minoritaria. Tras estos pasos, la tabla analítica contiene **195.946 siniestros**.

4.3 Inconsistencias, categorías ambiguas y errores de captura

Consistencia de la variable objetivo. Se contrastó la gravedad registrada en `SINIESTROS` con el estado de los actores en `ACTOR_VIAL` (un siniestro "con muertos" debe tener

Cuadro 5: Auditoría de integridad de la fuente.

Verificación	Resultado	Tratamiento
Registros exactamente duplicados (siniestros / actores / vehículos)	0 / 0 / 0	Ninguno requerido
Llaves duplicadas (CODIGO_ACCIDENTE / CODIGO_ACCIDENTADO / VEHICULO)	0 / 0 / 0	Ninguno requerido
Registros huérfanos de actores y vehículos (sin siniestro)	0 / 0	Integridad referencial correcta
Fechas u horas inválidas	0 / 0	Ninguno requerido; fechas dd/mm/aaaa convertidas a Date
Direcciones con espacios espurios	162	Normalizadas con str_squish() y mayúsculas
Siniestros sin actores ni vehículos registrados	148	Eliminados: sin atributos que modelar
Duplicados semánticos (mismo instante, dirección, clase, localidad, gravedad y tamaño)	58	Eliminados (distinct), se conserva el primer registro

al menos un actor muerto; uno “con heridos”, al menos uno herido y ninguno muerto).

Cuadro 6: Gravedad registrada frente a la evidencia a nivel de víctima (siniestros con detalle).

Gravedad registrada	Actores: muerto	Actores: herido	Actores: ilesos
1 Con muertos	2.991	3	1
2 Con heridos	2	65.101	111
3 Solo daños	0	58	127.737

Se hallaron 175 contradicciones (0,09 % de los registros). **Decisión:** prevalece la evidencia a nivel de víctima porque es la fuente primaria del conteo de heridos y muertos; la gravedad original se conserva en `gravedad_original` para trazabilidad. Es una corrección determinista que no aprende parámetros de los datos.

Categorías ambiguas o no documentadas.

- `CHOQUE` contiene el código 5 en 290 siniestros, ausente del diccionario oficial, y `OBJETO_FIJO` presenta códigos 15 y 16 en 7 registros. Se recodifican como “Otro (código no documentado)” en lugar de inventar una interpretación.
- `CHOQUE` vacío: no es un dato faltante sino estructural (28.237 de los vacíos corresponden a siniestros que no son choques); se recodifica como “No aplica (no es choque)”. Los 5 vacíos restantes pasan a “Sin información”.
- `CLASE` del vehículo vacía en 0,77 % de los vehículos: se asigna el código 18 “No identificado” del propio diccionario. `SERVICIO` vacío o 0 se trata como categoría sin información y no entra en indicadores.

Errores en la edad.

La edad **118** aparece 282 veces, mientras que las edades vecinas 110–117 casi no aparecen: es el patrón típico de un valor por defecto, no de personas de 118 años. Se conservan, en cambio, los valores altos plausibles (hasta 107 años en los datos) porque corresponden a peatones adultos mayores, justamente un perfil vulnerable de interés.

Cuadro 7: Errores de captura en la edad de los actores viales.

Problema	Registros de actores	Tratamiento
Edad reportada como ”SIN INFORMACION”	7.911	Pasa a NA y se imputa en Train
Edad 118 (valor repetido, probable código centinela)	282	Pasa a NA
Edad ≥ 110 años (incluye el código 118)	303	Pasa a NA: imposible o centinela
Conductores y motociclistas menores de 10 años	297	Pasa a NA: físicamente imposible

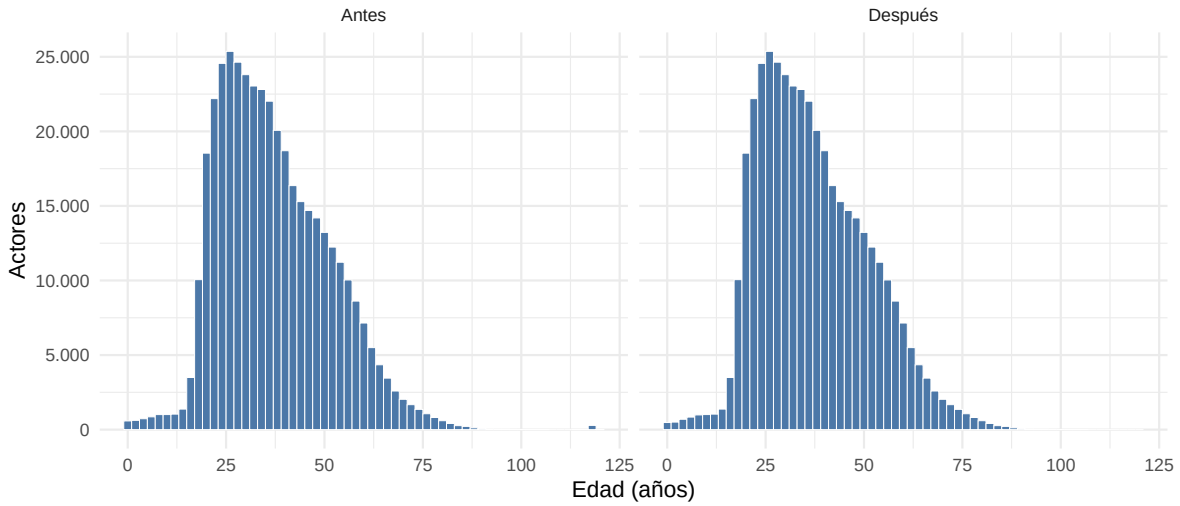


Figura 1: Edad de los actores viales antes y después de las reglas de dominio. Se elimina el pico centinela en 118 y las edades imposibles para conducir.

4.4 Partición estratificada Train/Test

Antes de calcular cualquier estadística se separa el conjunto en **70 % Train y 30 % Test**, estratificando por gravedad para conservar la proporción de la clase minoritaria, con semilla fija (`set.seed`, valor 2025).

Cuadro 8: Partición estratificada: la proporción de cada clase es prácticamente idéntica en Train y Test.

Conjunto	Gravedad	Siniestros	%
Train	Con muertos	2.095	1,53
Train	Con heridos	45.609	33,25
Train	Solo danos	89.458	65,22
Test	Con muertos	898	1,53
Test	Con heridos	19.547	33,25
Test	Solo danos	38.339	65,22
Total	Con muertos	2.993	1,53
Total	Con heridos	65.156	33,25
Total	Solo danos	127.797	65,22

A partir de este punto **todo ajuste usa únicamente el Train** (137.162 siniestros). El Test (58.784) solo recibe transformaciones ya aprendidas.

4.5 Valores faltantes: diagnóstico y estrategia

4.5.1 Auditoría de nulos en la fuente

Cuadro 9: Diagnóstico de valores vacíos en los datos crudos. La mayoría son estructurales y no deben imputarse.

Hoja	Variable	% vacío	Naturaleza	Tratamiento
SINIESTROS	CHOQUE	14,40	Estructural (solo si clase = choque)	Recodificar: No aplica / Sin información
SINIESTROS	OBJETO_FIJO	96,59	Estructural (solo si choque = objeto fijo)	Variable descartada
ACTOR_VIAL	EDAD (”SIN INFORMACION”)	1,87	Aleatoria condicionada a la condición del actor	Mediana de Train + indicador
ACTOR_VIAL	VEHICULO	5,55	Estructural (el peatón no tiene vehículo)	Sin acción (no se usa)
VEHICULOS	CLASE	0,77	Dato no capturado	Categoría ”No identificado”
VEHICULOS	SERVICIO	4,22	Dato no capturado	Categoría ”Sin información”
VEHICULOS	MODALIDAD	61,33	Estructural (solo transporte público)	Variable descartada

La lección central es que **un vacío no siempre es un dato perdido**: imputar `CHOQUE` u `OBJETO_FIJO` habría inventado información. El único faltante genuino relevante es la **edad** (y, derivada de ella y del sexo, la composición por edad y sexo de los involucrados).

4.5.2 Patrón de ausencia de la edad

A nivel de actor, la ausencia de edad no es homogénea: varía de 0,67 % (pasajero/acompañante) a 2,66 % (peatón). Una prueba χ^2 de independencia entre ausencia de edad y condición del actor rechaza la hipótesis de ausencia completamente al azar ($\chi^2 = 918{,}7$, p < 0,001). La ausencia tampoco es constante en el tiempo: pasó de 1,72 % en 2015 a 2,81 % en 2020. El patrón es compatible con ausencia al azar condicionada a variables observadas (MAR): depende de quién es el actor y de cuándo se registró, no del valor de la edad en sí.

Al agregar las edades a nivel de siniestro, la edad media queda sin dato solo cuando **ningún** involucrado tiene edad registrada: 476 siniestros en Train (0,35 %). La gravedad entre esos siniestros (6,30 % fatales) frente al resto (1,51 %) difiere significativamente (p < 0,001). Es un hallazgo importante: **la ausencia de edad es informativa**. La explicación está en los propios datos: en 64 % de esos siniestros hay un vehículo que huyó del lugar, frente a 2,5 % en el resto; es decir, el conductor no pudo ser identificado, y el vacío contiene información sobre la gravedad. Por eso (a) no se eliminan esos siniestros y (b) se conserva obligatoriamente el indicador `edad_imputada` como predictor, de modo que la imputación no «borre» esa señal.

4.5.3 Estrategia aplicada

Dado que (i) el faltante a nivel de siniestro es muy pequeño (0,35 %, muy por debajo del umbral práctico del 5 % a partir del cual la imputación suele distorsionar la distribución), (ii) la edad tiene sesgo a la derecha y (iii) la eliminación de filas sacaría del Train justamente siniestros con perfiles específicos, se adopta **imputación por mediana calculada en Train**, acompañada de un indicador `edad_imputada` que permite al modelo (y al analista) detectar los casos imputados. Un modelo KNN no se justifica: añade complejidad y costo computacional para un faltante inferior al 1 % y requeriría definir una métrica de distancia sobre variables mixtas. La imputación de `prop_mujeres` sigue la misma regla.

Cuadro 10: Parámetros de imputación aprendidos en Train y aplicados idénticamente a Test.

Variable	Nulos en Train	Mediana de Train (valor imputado)	Nulos tras imputar
edad_media	476	37,333	0
edad_min	476	29,000	0
edad_max	476	45,000	0
prop_mujeres	522	0,000	0

4.6 Valores atípicos (outliers)

La detección analítica se hace **sobre Train** y para las variables numéricas continuas o de conteo. Se comparan tres reglas: rango intercuartílico (IQR) con factor 1,5 y 3, Z-score con umbral 3 y percentil 99,5.

Cuadro 11: Porcentaje de Train marcado como atípico según cada regla.

Variable	IQR 1,5	IQR 3,0	Z > 3	> P99,5
n_vehiculos	22,46	22,46	0,63	0,11
n_clases_veh	0,07	0,00	0,07	0,07
n_conductores	0,44	0,02	0,44	0,44
n_vulnerables	0,57	0,02	0,57	0,08
n_involucrados	13,56	13,56	0,88	0,16
n_vehiculos_pesados	0,09	0,00	0,09	0,09
edad_media	0,84	0,01	0,47	0,47
edad_min	2,89	0,12	0,90	0,48
edad_max	0,44	0,00	0,30	0,42

La tabla muestra por qué **ninguna regla puede aplicarse a ciegas**:

- Para las variables de conteo (`n_vehiculos`, `n_involucrados`, …), el IQR es cero o casi cero porque la mayoría de los siniestros tienen exactamente dos vehículos. La regla IQR 1,5 marcaría como «atípico» tanto al siniestro de un solo vehículo como al de tres o más: más de una quinta parte del Train, que son eventos perfectamente legítimos.
- En las edades, el IQR marca sobre todo a los extremos plausibles (adultos mayores, menores), no errores de captura.

Se adopta una política diferenciada y documentada:

Cuadro 12: Política de tratamiento de valores atípicos.

Grupo	Decisión	Justificación
Edades (media, mín., máx.)	Conservar los valores plausibles (hasta 109 años): son anomalías legítimas (peatones mayores)	Eliminarlos borraría el perfil más vulnerable
Conteos (vehículos, conductores, vulnerables, involucrados, pesados, clases)	Acotar (winsorizar) al percentil 99,5 de Train: se conserva el siniestro, pero se limita la influencia de colisiones masivas	Un evento con más de 20 vehículos tiene leverage desproporcionado en escalas y distancias
Valores imposibles (edad ≥ 110, conductor < 10 años)	Anular y tratar como faltante (Sección 4.5)	Son errores de captura, no extremos

Cuadro 13: Winsorización: topes aprendidos en Train y filas afectadas.

Variable	Tope (P99,5 de Train)	Máximo antes	Filas acotadas	% de Train
n_vehiculos	4	23	149	0,109
n_clases_veh	3	5	100	0,073
n_conductores	3	23	600	0,437
n_vulnerables	3	16	111	0,081
n_involucrados	4	23	219	0,160
n_vehiculos_pesados	2	4	126	0,092

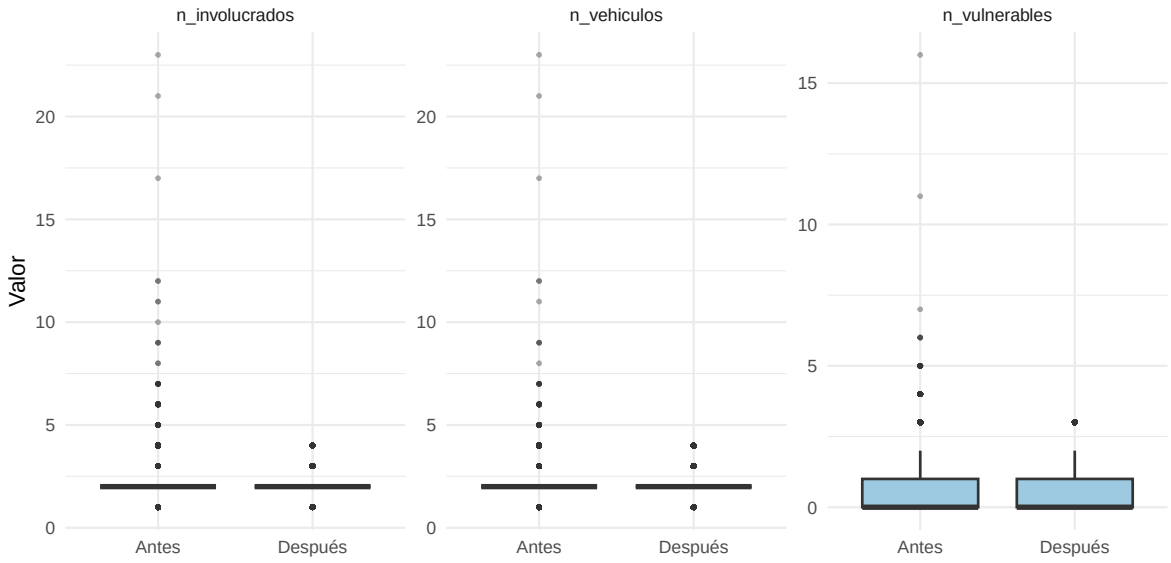


Figura 2: Efecto de la winsorización (percentil 99,5 de Train) sobre las variables de conteo: se acota la cola sin eliminar siniestros.

5 Fase 4 de KDD — Transformación e ingeniería de características

5.1 Variables derivadas

Todas las variables derivadas son deterministas y se calculan **sin usar el estado de los actores ni los pasajeros**.

Cuadro 14: Variables derivadas, definición y relevancia.

Grupo	Variable	Definición	Relevancia para el negocio
Temporal	franja_horaria	Madrugada 00–05h, Pico AM 06–08h, Valle diurno 09–15h, Pico PM 16–19h, Noche 20–23h	H2; operativos por franja
Temporal	nocturno	1 si la hora es ≥ 20 o < 6	H2
Temporal	fin_semana / es_festivo / dia_no_habil	Sábado-domingo; festivos de Colombia (Ley Emiliani y Semana Santa, calculados por reglas); unión de ambos	H2; los festivos se comportan como fin de semana
Temporal	hora_sin, hora_cos, mes_sin, mes_cos	Codificación cíclica de hora y mes	Evita el salto artificial 23h → 0h y dic → ene
Involucrados	hay_peaton / hay_ciclista / hay_motociclista	Presencia de cada actor vulnerable	H1
Involucrados	n_vulnerables, ratio_vulnerables	Nº de peatones+ciclistas+motociclistas y su fracción sobre los involucrados	H1; exposición relativa
Involucrados	hay_menor, hay_adulto_mayor	Algún actor < 18 años; algún actor ≥ 65 años	Campañas dirigidas
Involucrados	edad_media, edad_min, edad_max, prop_mujeres	Agregados por siniestro (sin pasajeros)	Perfiles etarios y de género
Vehículos	n_vehiculos, multi_vehiculo	Cantidad de vehículos y si hay más de uno	Complejidad del evento
Vehículos	n_clases_veh, indice_heterogeneidad	Clases distintas e índice de Gini-Simpson sobre las clases de vehículo (0 = homogéneo)	Heterogeneidad de la masa vehicular
Vehículos	hay_pesado, n_vehiculos_pesados	Presencia/cantidad de carga pesada o buses	Energía del impacto
Vehículos	hay_moto_vehiculo, hay_transporte_publico, hay_fuga	Moto entre los vehículos; servicio público; vehículo que huyó	Focalización de control
Interacción	mezcla_vulnerable_pesado	1 si hay un actor vulnerable y un vehículo pesado en el mismo siniestro	Combinación de riesgo conocida
Lugar	via_avenida	Dirección sobre avenida (AV, AK, AC, AU)	Corredores arteriales

La heterogeneidad se mide con el índice de Gini-Simpson, $1 - \sum_k p_k^2$, donde p_k es la proporción de vehículos de la clase k en el siniestro: vale 0 si todos los vehículos son de la misma clase y crece cuanto más mezclado es el parque implicado.

5.2 Codificación de variables categóricas

- **One-hot (k−1 columnas)** para las nominales: `clase_siniestro`, `tipo_choque`, `diseno_lugar`, `localidad`, `franja_horaria` y `dia_semana`. Se omite la categoría de referencia, que es la **moda de Train**, para evitar multicolinealidad exacta (clase_siniestro = Choque; tipo_choque = Vehiculo; diseno_lugar = Tramo de Via; localidad = Kennedy; franja_horaria = Valle diurno (09-15h); dia_semana = Viernes).
- **Categorías raras:** niveles con frecuencia inferior a 0,5 % en Train se agrupan en "Otros"; esto incluye cualquier nivel que aparezca en el futuro y no haya sido visto en Train.
- **Binarias** (0/1) se dejan como están.
- **Variable objetivo** como factor ordenado: Solo daños < Con heridos < Con muertos.

Cuadro 15: Codificación one-hot: niveles retenidos y columnas generadas.

Variable	Niveles en datos	Niveles retenidos	Columnas dummy
clase_siniestro	7	4	4
tipo_choque	7	3	3
diseno_lugar	12	5	5
localidad	20	19	19
franja_horaria	5	5	4
dia_semana	7	7	6

5.3 Normalización de atributos numéricos

Se estandariza con **Z-score** (`(x − media_Train) / desvío_Train`) las 12 variables numéricas, porque los algoritmos previstos para la siguiente fase (regresión logística regularizada, k-medias y PCA) son sensibles a la escala. Los modelos basados en árboles no lo requieren, pero tampoco se perjudican. El orden es: imputar → winsorizar → estandarizar, todo con parámetros de Train.

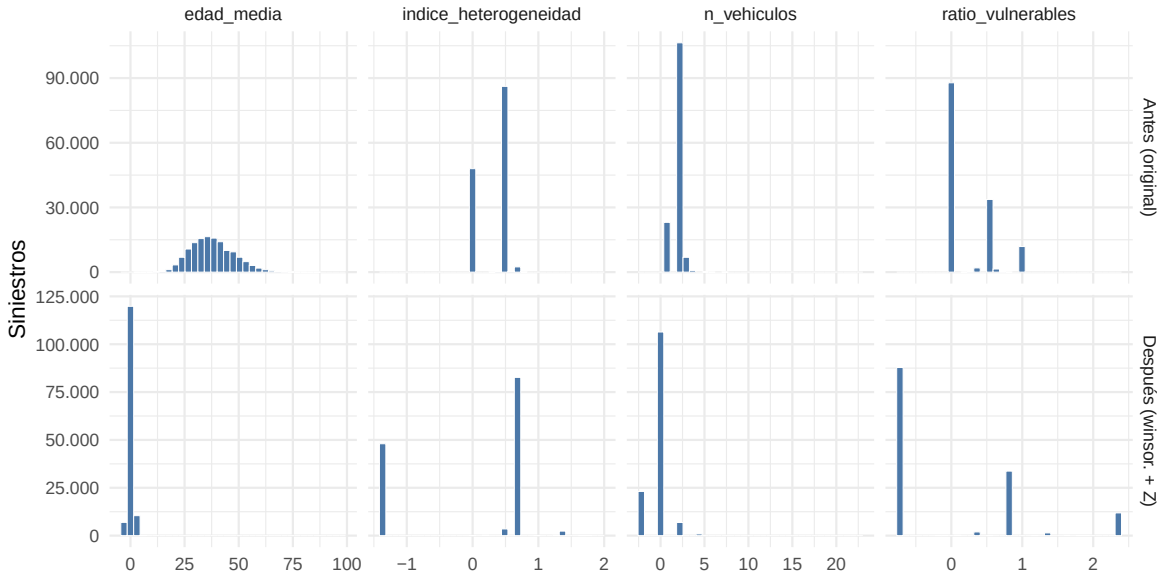


Figura 3: Antes y después de la transformación (Train). Arriba: valores originales; abajo: valores acotados y estandarizados con media y desvío de Train.

Cuadro 16: Evidencia tabular de la normalización. En Train la media es 0 y el desvío 1 por construcción; en Test se aproximan a esos valores pero no coinciden exactamente, señal de que Test no participó en el ajuste.

Variable	Media Train (antes)	Desvío Train (antes)	Media tras Z (Train)	Desvío tras Z (Train)	Media tras Z (Test)	Desvío tras Z (Test)
n_vehiculos	1,896	0,501	0	1	-0,003	1,001
n_clases_veh	1,671	0,514	0	1	0,000	1,001
n_conductores	1,563	0,727	0	1	0,005	0,994
n_vulnerables	0,453	0,673	0	1	-0,007	0,995
n_involucrados	2,016	0,429	0	1	-0,002	1,005
n_vehiculos_pesados	0,424	0,575	0	1	-0,003	0,993
edad_media	37,971	9,853	0	1	0,007	1,000
edad_min	30,742	10,014	0	1	0,008	1,006
edad_max	45,263	13,087	0	1	0,005	0,998
prop_mujeres	0,121	0,239	0	1	-0,003	0,995
indice_heterogeneidad	0,327	0,241	0	1	0,000	1,000
ratio_vulnerables	0,222	0,325	0	1	-0,007	0,994

5.4 Reducción de dimensionalidad: PCA

Se ajusta un análisis de componentes principales sobre el bloque numérico estandarizado de Train y se proyecta el Test con la misma rotación. Su propósito en el proyecto es doble: diagnosticar la redundancia entre variables y disponer de un espacio reducido para el agrupamiento (objetivo específico 5).

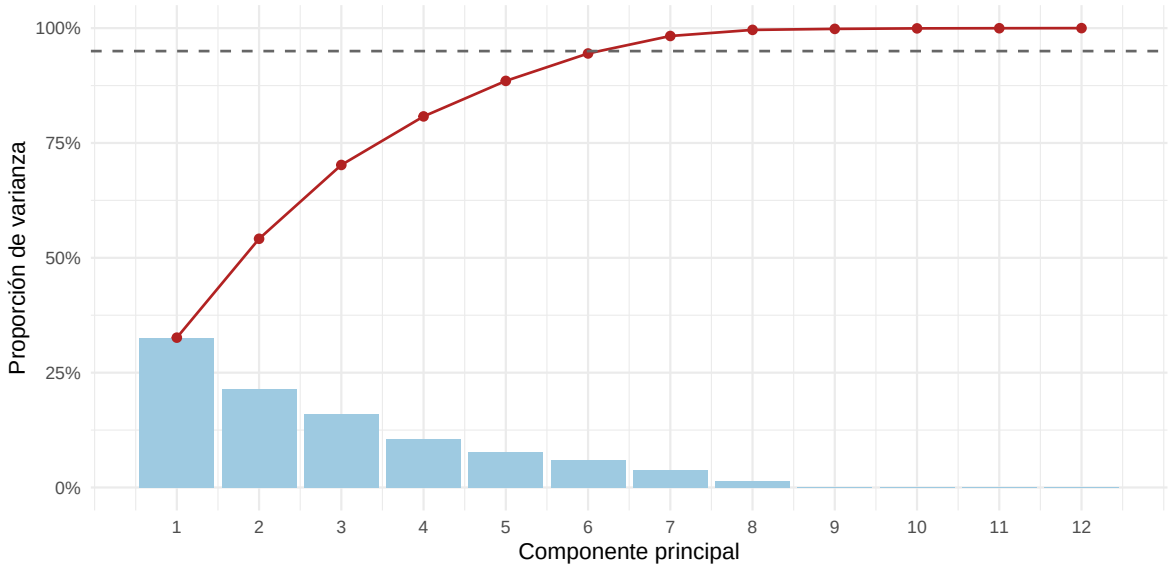


Figura 4: PCA sobre las variables numéricas estandarizadas de Train: varianza explicada por componente y acumulada.

Se necesitan **7 componentes para retener al menos el 95 %** de la varianza de las 12 variables numéricas (98,3 %), lo que indica una redundancia moderada (por ejemplo entre `n_vehiculos`, `n_conductores` y `n_clases_veh`): cinco dimensiones pueden descartarse perdiendo menos del 5 % de la varianza. Las cargas principales son:

Cuadro 17: Cargas de las tres primeras componentes (Train).

Variable	PC1	PC2	PC3
n_vehiculos	0,36	0,28	0,14
n_clases_veh	0,31	0,35	0,23
n_conductores	0,45	-0,02	-0,20
n_vulnerables	-0,37	0,20	0,40
n_involucrados	0,18	0,30	0,32
n_vehiculos_pesados	0,22	0,01	-0,14
edad_media	0,19	-0,45	0,40
edad_min	0,17	-0,45	0,20
edad_max	0,17	-0,34	0,46
prop_mujeres	-0,09	-0,01	0,11
indice_heterogeneidad	0,29	0,34	0,21
ratio_vulnerables	-0,40	0,17	0,36

La primera componente contrapone los eventos **entre vehículos con conductores** (cargas positivas en conductores y vehículos) a los eventos **con actores vulnerables** (cargas negativas en vulnerables y su proporción); la segunda está dominada por la **edad de los involucrados** (cargas negativas) junto con la diversidad de vehículos; la tercera combina **vulnerables, edad máxima y heterogeneidad**. Como los árboles y la regresión regularizada pueden operar sobre las variables originales, las componentes principales se guardan como un conjunto alterno (`datos/clean/train_pca.rds`), no como reemplazo.

5.5 Verificación anti-fuga de datos

Se implementaron cuatro pruebas explícitas, que el informe ejecuta cada vez que se compila:

Cuadro 18: Pruebas automáticas contra fuga de datos y reproducibilidad.

Prueba	Resultado
Idempotencia: re-aplicar aplicar_transformacion() con los parámetros guardados reproduce exactamente Train y Test	APROBADA
Train y Test comparten las mismas columnas, en el mismo orden y sin vacíos	APROBADA
Ningún siniestro está en Train y Test a la vez	APROBADA
Los parámetros provienen solo de Train (la media de Test tras Z no es exactamente 0)	APROBADA

Para dimensionar el riesgo evitado, la siguiente tabla compara los parámetros que se habrían obtenido, por error, usando **todo** el conjunto frente a los que se usan realmente (solo Train). Con 195.946 filas la diferencia numérica es mínima (aparece en el tercer o cuarto decimal); el punto es metodológico: la contaminación es sistemática, crece cuando las muestras son pequeñas o las clases raras (como la fatal) y haría que la evaluación en Test fuera optimista.

Cuadro 19: Parámetros calculados solo con Train frente a los que resultarían con fuga.

Parámetro	Solo Train (correcto)	Todo el conjunto (con fuga)
Mediana de edad_media	37,3333	37,5000
Tope P99,5 de n_vehiculos	4,0000	4,0000
Media de n_involucrados	2,0131	2,0129
Desvío de n_involucrados	0,4022	0,4028

6 Exploración sobre el conjunto Train

Para no «mirar» el Test antes de tiempo, la caracterización exploratoria (objetivo específico 2) se realiza **solo con Train**. Los resultados son orientativos: la contrastación formal de las hipótesis corresponde a la fase de modelamiento.

6.1 Desbalance de la variable objetivo

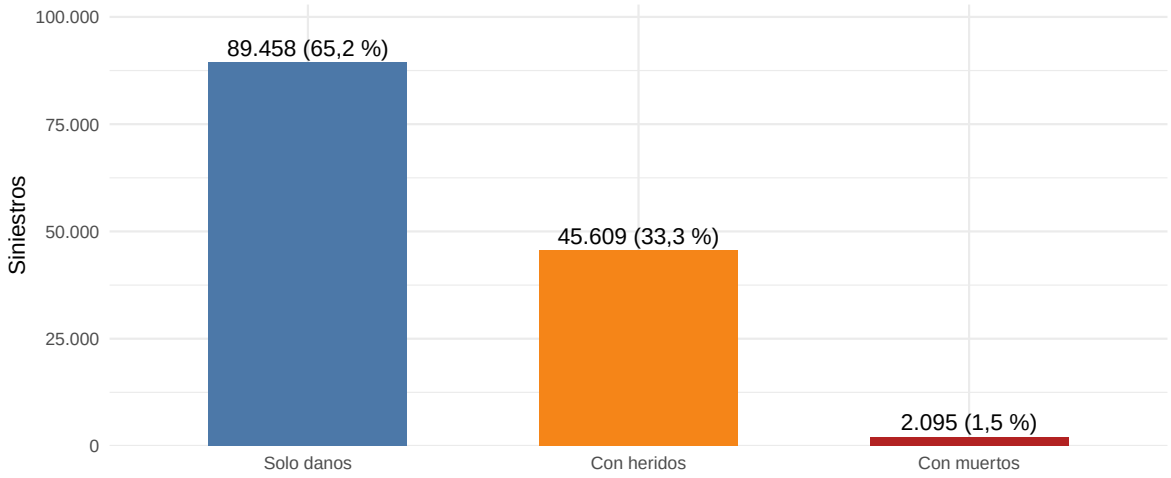


Figura 5: Distribución de la gravedad en Train. Los siniestros fatales son una pequeña fracción.

La razón entre la clase mayoritaria y la minoritaria es de **43 a 1**. Con esta proporción, un clasificador que prediga siempre "Solo daños" alcanzaría 65,2 % de accuracy sin detectar un solo siniestro fatal; por eso se evaluará con recall por clase, F1 macro, matriz de confusión y AUC. Se prevé aplicar el tratamiento del desbalance (ponderación de clases o remuestreo) **únicamente dentro de Train**, nunca sobre Test.

6.2 Franja horaria, tipo de día y localidad

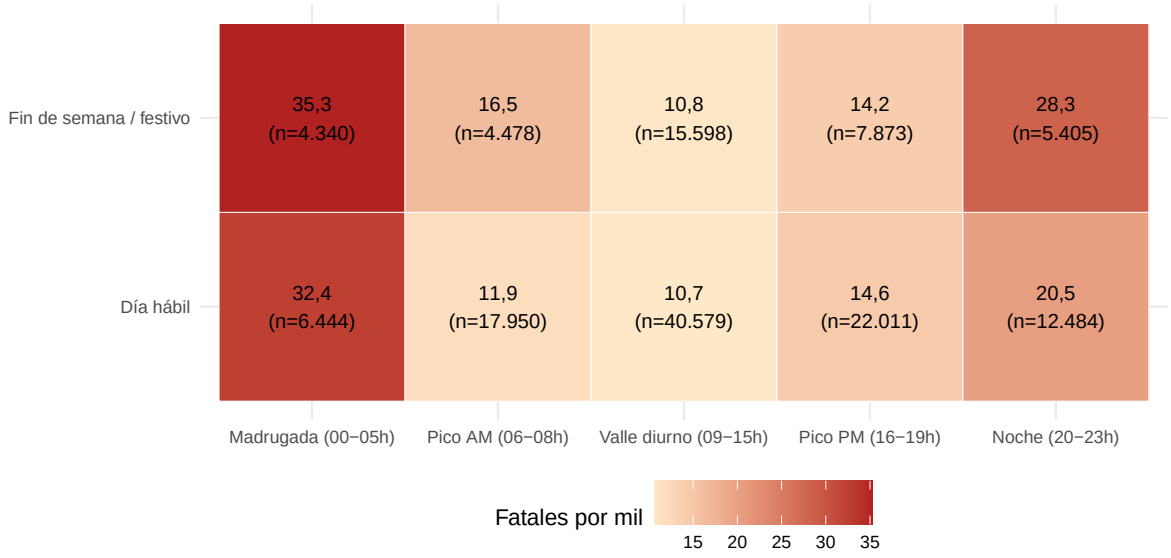


Figura 6: Siniestros fatales por cada 1.000 siniestros (Train), según franja horaria y tipo de día.

Lectura exploratoria (H2): la tasa de fatalidad en horario nocturno es de 26,9 por mil frente a 12,2 por mil en horario diurno ($p < 0{,}001$). Los días no hábiles registran 17,5 por mil frente a 14,4 por mil en días hábiles ($p < 0{,}001$). Es una asociación bivariada, que no controla por clase de siniestro ni por tipo de actor y que será re-evaluada en el modelo multivariado.

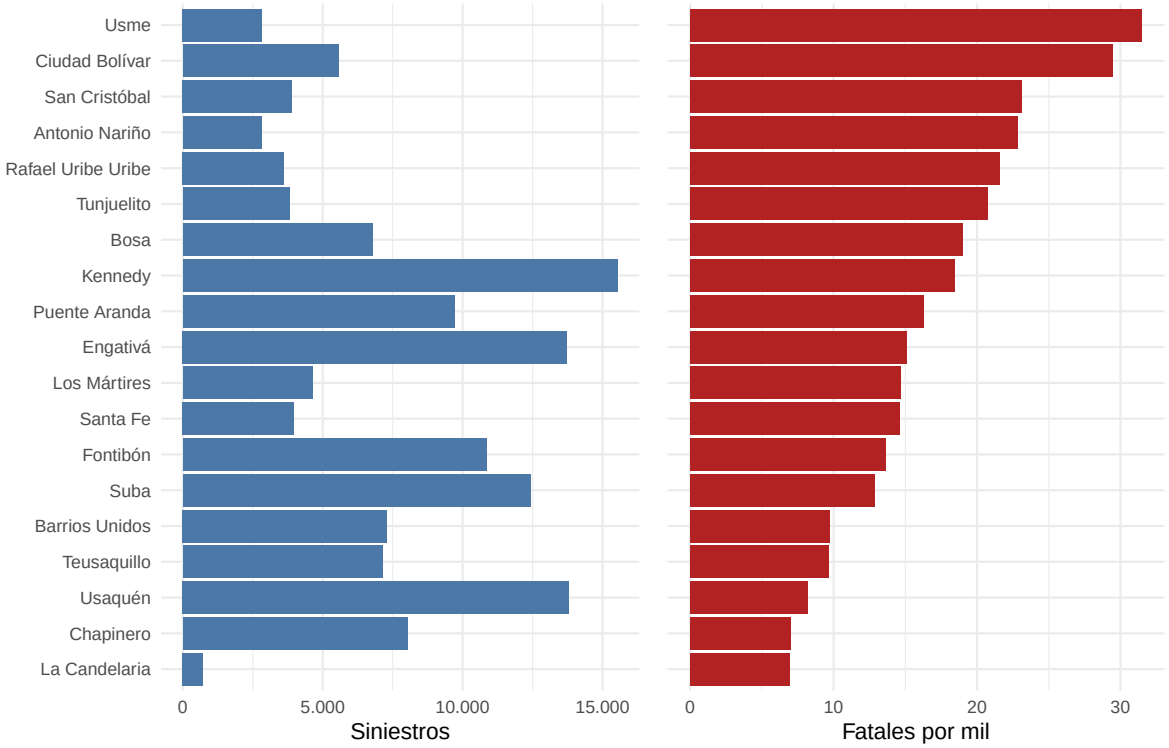


Figura 7: Localidades: volumen de siniestros (izquierda) y tasa de fatalidad por mil siniestros (derecha), solo Train.

El volumen de siniestros y su letalidad **no coinciden**: las localidades con más siniestros no son, en general, las de mayor proporción de eventos fatales. Esa diferencia justifica evaluar la focalización con la tasa de fatalidad y no solo con conteos absolutos.

6.3 Actores viales vulnerables

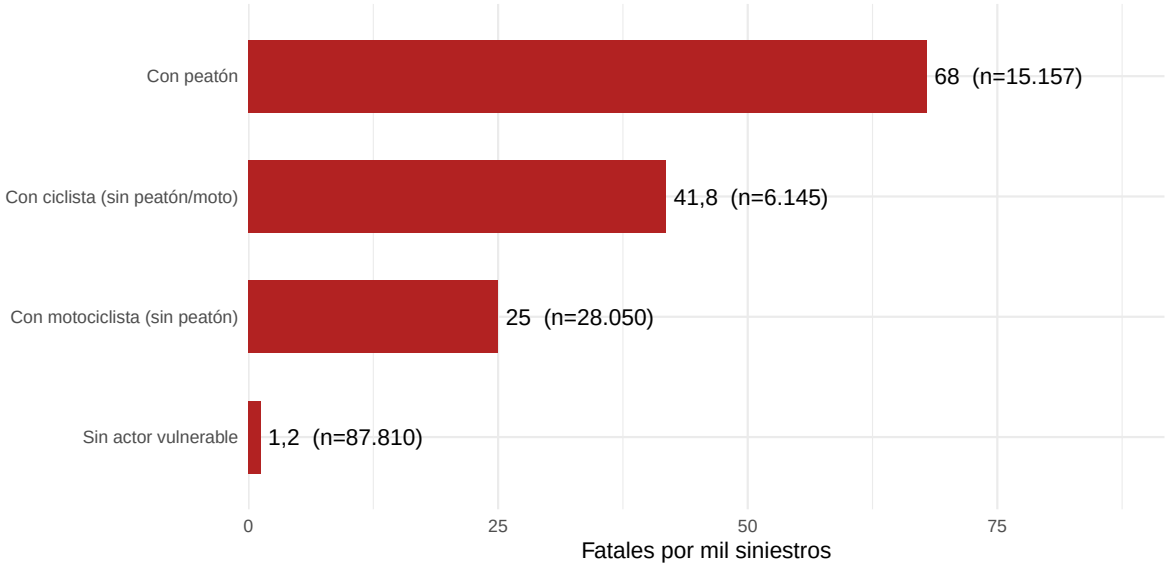


Figura 8: Siniestros fatales por mil siniestros según el actor vulnerable involucrado (Train).

Los siniestros con peatón tienen una tasa de fatalidad 56,3 veces la de los siniestros sin actor vulnerable. En conjunto, la presencia de algún actor vulnerable se asocia con 40,3 fatales por mil frente a 1,2 por mil en su ausencia ($p < 0{,}001$). Como se advirtió en la Sección 3.4, parte de esta diferencia es mecánica (un atropello rara vez deja ileso al peatón) y deberá interpretarse con cautela en el modelamiento.

7 Conclusiones de la entrega y trabajo siguiente

7.1 Lecciones aprendidas

1. **La integración exigió decisiones de diseño, no solo uniones.** Pasar de tres granularidades a una fila por siniestro obligó a decidir qué información de los actores es legítima como predictor.
2. **La base contiene una fuga de objetivo estructural.** Los pasajeros solo se registran si resultan lesionados; ignorarlo habría producido modelos engañosamente buenos. Se excluyeron de todas las variables derivadas.
3. **Los vacíos son mayoritariamente estructurales, y el que no lo es es informativo.** Solo la edad es un faltante genuino (menos del 1 % a nivel de siniestro), pero su ausencia se asocia con mayor letalidad; por eso se imputa y se conserva un indicador.
4. **Los valores atípicos requieren criterio de dominio.** Las reglas estadísticas ciegas habrían eliminado adultos mayores y colisiones múltiples reales; en cambio los errores (edad 118, conductores de 0 a 9 años) sí fueron corregidos.

5. **La variable objetivo también se audita.** Se reconciliaron 175 siniestros con evidencia contradictoria.
6. **La partición estratificada y el flujo anti-fuga** (ajuste solo en Train, aplicación idempotente) quedaron automatizados y verificados en cada compilación.

7.2 Limitaciones técnicas

- El consolidado cubre 2015–2020, es decir, **no incluye los años posteriores a 2020 ni la línea base 2022** del Plan Distrital; los patrones del año 2020 reflejan además las restricciones de movilidad de la pandemia. Un modelo entrenado con estos datos requerirá actualización antes de uso operativo.
- El registro depende del diligenciamiento del IPAT; existen sesgos de subregistro, especialmente en siniestros de solo daños.
- No se dispone de datos de **exposición** (flujo vehicular, kilómetros recorridos), por lo que las tasas son por siniestro registrado y no por unidad de exposición.
- La partición aleatoria estratificada no mide la deriva temporal; la validación temporal (entrenar con años anteriores, probar con el último) se evaluará en la siguiente fase.

7.3 Trabajo futuro (siguientes entregas)

- **Minería de datos (KDD 5):** comparar al menos tres clasificadores (regresión logística multinomial regularizada, árbol/bosque aleatorio y gradient boosting) con validación cruzada estratificada solo en Train, ajuste por desbalance dentro de cada pliegue, y reporte de matrices de confusión, recall por clase, F1 macro y AUC.
- **Agrupamiento:** k-medias o k-medoides sobre el espacio PCA para identificar perfiles de riesgo (localidad × franja × actor).
- **Interpretación:** importancia de variables y valores SHAP, traducidos a reglas operativas.
- **Despliegue (CRISP-DM 6):** servicio o tablero en R (Plumber o Shiny) que reutilice `modelos/parametros_transformacion.rds` y `aplicar_transformacion()` para transformar casos nuevos con los mismos parámetros de Train.

Anexos

Anexo A. Estructura del proyecto entregado

```
mineria_siniestros_bogota/
├── informe_final.Rmd            # este informe (rutas relativas)
├── informe_final.pdf            # informe compilado
├── scripts/
│   ├── 00_descarga_datos.R      # descarga y exporta el consolidado oficial
│   ├── 01_integracion_limpieza.R     # reglas deterministas + integración
```

```
│   ├── 02_particion_transformacion.R # partición, ajuste (Train), transformación
│   └── funciones.R                   # ajustar_/aplicar_transformacion()
├── datos/
│   ├── raw/                      # CSV crudos por hoja
│   └── clean/                    # integrado, Train/Test (legible, ML, PCA)
├── modelos/
│   └── parametros_transformacion.rds # parámetros aprendidos en Train
└── resultados/auditoria_limpieza.rds # contadores de la auditoría
```

Anexo B. Columnas del conjunto de modelamiento

Cuadro 20: Composición del conjunto de modelamiento (Train y Test en formato ML).

Tipo	Columnas
Identificador y objetivo	2
Numéricas estandarizadas (Z)	12
Binarias 0/1	18
Cíclicas	4
One-hot (k−1)	41
Total	**77**

Anexo C. Entorno de ejecución

```
R version 4.3.3 (2024-02-29)
Plataforma: x86_64-pc-linux-gnu (64-bit)
Semilla de partición: 2025
```